

企业财务违规的机器学习识别模型 ——基于凯乐科技案例的考察

黄 英¹, 康晓佳¹, 唐 凯^{2*}

(1. 浙江大学 管理学院, 浙江 杭州 310058; 2. 中山大学 管理学院, 广东 广州 510006)

摘要:精准识别企业的财务违规风险是构建公平有效资本市场的重要前提。本文结合使用大样本实证检验与案例分析的研究方法,以三角形理论为基础,搭建通过显著性检验与算法约简的指标体系,在比较朴素贝叶斯、CART 决策树、梯度提升机、XGBoost 模型等多种机器学习方法的识别结果后,挑选出最适的估计方法组合,并构建财务违规识别模型。进一步地,本文将所构建模型应用于符合“理论抽样”原则的凯乐科技案例,直观地展现出财务违规识别模型的工作机理与结果。研究发现,本文所构建的模型能够精准地识别凯乐科技的财务违规风险,且具体地展现了“机会”“借口”“压力”三方面的风险来源。该识别模型及其实例应用有助于精准预测企业的财务违规风险,并为打开识别模型的工作“黑箱”贡献证据。

关键词:财务违规;机器学习;识别模型;三角形理论

中图分类号:F23 **文献标识码:**A **文章编号:**1004-6062(2026)05-0061-016

DOI:10.13587/j.cnki.jieem.2026.05.005

0 引言

“加大重点领域财会监督力度,严厉打击财务会计违法违规行”是我国 2023 年出台的《关于进一步加强财会监督工作的意见》中的核心要义。财务违规泛指企业违反会计法律与规定的行为,财务舞弊是其中备受关注的子集。企业财务违规事件已在世界范围内产生巨大影响。例如,导致《萨班斯-奥克斯利法案》出台的安然事件与世界通讯公司事件。同时,伴随市场制度与经济业态的迭代,操纵市场与内部交易等非舞弊类违规行为越发普遍,已严重干扰资本市场资源配置功能的实现。据国泰安数据库统计,我国 2022 全年便有 1108 家上市公司出现财务违规行为,恒大集团亦因此陷入舆论风波。此类事件凸显出财务违规对经济可持续发展的致命危害。因此,识别并干预财务违规事件的发生,是从源头上保证资本市场公平有序发展的重要前提,亦是各界人士十分关注的问题。

识别企业财务违规已受到广泛且持续的重视。从识别要素方面来看,现有研究立足企业内部的财务指标^[1-4]、非财务指标^[5-9]与外部的分析师及媒体等非正式制度视角^[10-11],探究财务违规的影响因素。从识别方法方面来看,早期研究使用经验推理或统计模型等传统方法识别企业的财务违规,但具有客观性不足与应用性缺乏的弊端。信息技术的发展为从文

本等非结构数据中挖掘更多违规因素提供了可行性^[12-15],如何将此类因素综合纳入以机器学习为代表的新兴方法^[15-19],从而提高识别准度与效率,已成为一个重要研究议题。此外,如何立足内容更为丰富的财务违规视角,将企业的内外部因素、财务与非财务指标及结构与非结构数据囊括在同一指标体系中,并在理论指引下使用精准的机器学习方法识别企业的财务违规,成为了一项迫切任务。

鉴于此,本文尝试构建能够精准识别企业财务违规的模型,并将其应用于实例,以期为资本市场的监管与建设提供分析工具。具体地,本文首先对兼具代表性与启发性的凯乐科技财务违规案例进行回顾;其次,利用三角形理论从机会、借口与压力三个维度初步选择指标项目。经使用匹配后的违规样本剔除非显著项目后,利用算法进行约简,构建科学的指标体系;再者,使用朴素贝叶斯、CART 决策树、梯度提升机、XGBoost 模型等机器学习方法分别进行估计,并基于比较估计结果挑选出最适组合;此外,将所构建的识别模型应用于凯乐科技实例,以展现其应用过程。最后,本文随机抽取上市公司样本进一步证实所构建的识别模型具有较高普适性。研究发现,本文所构建的识别模型具有较高的信度与效度,能够准确识别凯乐科技的财务违规,并指出违规事件发生的深层原委。

收稿日期:2023-12-01

基金项目:浙江大学-悉尼大学种子基金项目(188170 * 194252404/002);中国统一战线理论研究会浙江研究基地

*** 通讯作者:**唐凯(1999—),男,辽宁铁岭人;中山大学管理学院会计学博士生;研究方向:审计、财务会计、公司治理、公司金融。

本文具有如下潜在贡献:第一,本文结合使用大样本实证与案例研究的方法,大幅提升研究的可靠性与直观性。识别企业财务违规经历了由经验判断法^[20]到统计模型法^[5,9,21]再到机器学习等^[15-19]新兴技术方法的转变。经验判断存在客观性不足的弊端;统计模型又因强假设条件而往往偏离实际;机器学习虽能大幅提升识别模型的有效性,但也会因过于技术化而损害可理解性。因此,本文在利用大样本数据构建基于机器学习方法的财务违规识别模型后,又新颖地对凯乐科技财务违规案例进行应用。这种融合既大幅提升所构建模型的识别有效性,又能够更直观地展现基于机器学习方法的识别过程“黑箱”。

第二,本文构建的识别模型理论基础坚实,指标合理,估计方法也比较有效。本文使用受到广泛认同的三角形理论来指导指标体系的构建及其中明细项目的选取。此做法能够保证所构建识别模型的学理性,且避免了指标项目挑选时的主观偏差问题。同时,本文在指标体系中创新地引入管理层语调等非结构化数据,及分析师与媒体关注等外部环境要素,从而拓宽了识别模型的指标来源。此外,本文在对比多种机器学习方法后,针对每种情形挑选出最适识别方法,以确保所构建模型兼具科学性与可行性。

第三,本文立足内涵更为丰富的企业财务违规视角构建识别模型,扩展了所构建模型的应用范围。企业财务违规中一个具备欺诈性质的典型子集便是财务舞弊^[22],现存识别模型多将其作为出发点^[16-17]。但资本市场中诸如内幕交易与股价操纵等非舞弊类违规行为的危害性与普遍性与日俱增。然而,现有研究针对此种非舞弊类财务违规行为的识别往往聚焦于单一违规行为进行分析^[18-19],缺乏综合性的考量。因此,本文以内容更为广泛的财务违规为基础构建识别模型,进而为全面预测资本市场的潜在风险提供理论解释与实践指引。

1 文献回顾与研究思路

1.1 相关理论评价

冰山理论、三角形理论、“GONE”理论和风险因子理论是解释企业财务违规成因的代表性理论。冰山理论又称二因素论,其将企业违约按照察觉容易度分成两类,且认为隐藏部分危险更大^[23];三角形理论认为企业财务违规是机会、借口与压力(动机)相互作用而共同产生的^[24];“GONE”理论则将财务违规的来源概括为贪婪、机会、需要和暴露四个维度^[25];风险因子理论将“GONE”理论的四因素重新分成个别与一般风险因子^[24]。上述理论的核心

差异在于分类标准的不同,需根据使用目标择优选取。

三角形理论在全面性与直观性方面兼具比较优势,且其在实践中的广泛应用亦证实此观点。一方面,其使用三个常见词汇作为要素,相比冰山理论更通俗易懂且足够全面;另一方面,“GONE”理论与风险因子理论是对三角形理论的细化,但亦引致烦琐复杂的弊端,折损了三角形理论优良的直观性与可操作性。实践中,中国审计准则第1141号及美国反舞弊准则(SAS No. 99)均以三角形理论为指引,审计人员亦遵循其开展企业财务违规的识别工作。可见,三角形理论在识别财务违规方面的优越性已获得权威部门的普遍认可。因而,本文后续也将以此为基础构建财务违规识别模型。

1.2 文献回顾

旨在防范财务违规问题的发生,现有研究利用企业内部的结构与非结构数据以及企业外部环境要素探讨财务违规的影响因素并构建识别模型。企业内部方面,自1960年以来,运用财务指标识别企业违规的研究开始出现^[1],并初具规模^[2-4]。伴随对内部控制与公司治理的重视,立足非财务指标探究违规影响因素的研究也大幅增加^[5-9]。此外,技术的发展亦为从文本等非结构数据中挖掘更多违规的影响因素提供了可能^[12-15]。从企业外部方面来看,围绕正式制度^[26]及分析师与媒体等非正式制度的探索也层出不穷^[10-11]。

识别企业财务违规的方法经历了由经验推理、到统计模型、再到新兴技术的不断演变。经验推理时期,相关研究主要局限于特定财务违规形式,且多使用专家判断、案例研究、描述性统计等基础方法进行推断^[20]。这便导致相关研究大多停留在财务违规特征与手段的阐释,缺少融合多种影响因素的量化分析。

统计模型时期,单变量检验^[26]与多元回归^[5,9]均被大量应用于企业财务违规的识别。但是,这两种方法亦存在一定缺陷。单变量检验高度依赖于单个变量的选取,获得的结论较为片面。多元回归方法需满足自变量间相互独立且服从一定分布特征的强假设条件。这些条件在现实经济活动中很难满足,所以识别的结果可能偏离实践。

新兴技术时期,机器学习等方法开始被运用,用于突破原有技术在识别财务违规方面的瓶颈^[27]。从结果反馈来看,支持向量构建的优化模型同时适配线性及非线性数据集^[28];决策树模型^[29-30]、神经网络模型^[18]、XGboost^[19]、集成学习法与深度学习法^[31]均能够提升预测的精度。而且,比较多种机器学习识别结果后择优选取的模型的有效性更

高^[15]。但因机器学习方法更为技术化,其识别过程仍旧难以被直观理解。

综上所述,第一,识别涵盖内容更为广泛的财务违规是一个受到广泛关注但仍需探索的问题;第二,三角形理论是分析企业财务违规成因的各理论中兼具直观性与全面性且备受认可的一个理论;第三,企业财务违规的识别指标除包含企业内的结构数据外,还应囊括非结构数据与外部环境要素;第四,使用机器学习方法构建财务违规识别模型能够拓展传统方法的适用范围并提升精准度与有效性;第五,立足中国独特的制度背景,运用机器学习方法构建识别模型的研究有待继续扩充,且机器学习方法的违规识别过程“黑箱”需进一步打开。

2 研究设计与案例介绍

2.1 研究方法

本文综合使用理论分析、大样本检验与案例应用等研究方法,并在构建企业财务违规识别模型的过程中引入多种机器学习方法以比较挑选。本文首先着眼于形式多样且不易察觉的财务违规视角,以属性优良且应用广泛的三角形理论为基础,从企业内部的结构与非结构数据,及企业外部的环境要素中初步选取识别的指标项目;其次,经中国上市公司违规样本匹配后,剔除不显著的指标项目,并使用算法进行约简;再次,同时使用 CART 决策树、支持向量机、梯度提升机、XGboost 算法等机器学习方法估计模型,并根据结果挑选出不同情景下的最适组合;此外,应用凯乐科技的案例检验模型有效性,并打开基于机器学习方法的识别模型的运作“黑箱”;最后,随机抽取一定数量的上市公司来验证所构建模型的普适性。

2.2 案例介绍

根据“理论抽样”原则^[32],典型性与启发性是案例选择的核心依据,以此保障案例具有较高普适性。本文所选取的湖北凯乐科技股份有限公司(下文简称“凯乐科技”)满足上述要求。第一,凯乐科技财务违规事件金额巨大,其被发现累计虚增营业收入 512 亿元;第二,凯乐科技财务违规持续时间较长,覆盖 2014~2023 年;第三,凯乐科技因高科技龙头企业等热点标签而拥有较高关注度,并在 2023 年成为 A 股第一家退市企业,引发了巨大市场舆论;第四,凯乐科技的违规事件不仅涉及财务舞弊,还涉及其余非舞弊类违规行为,契合研究目标。总之,无论是财务违规的情节严重性或是手段经典性,该案例均具有突出代表性。

凯乐科技于 2000 年登陆 A 股资本市场后,曾频繁变换主业,因此被冠以 A 股“故事大王”的称号。

自 2014 年起,其实施过多种财务违规行为,也不断遭受监管方的处罚。其财务违规形式不仅包括虚构利润、披露不实等舞弊行为,还包括了违规担保、推迟披露等其他非舞弊类财务违规行为。最终,凯乐科技于 2022 年 12 月被要求退市,并在 2023 年 2 月正式完成。自此,凯乐科技作为中国资本市场第 1000 家上市公司,戏剧性地成为 2023 年第一退市企业。

凯乐科技违规事件对其自身经营发展、在职高管、中小股东、债权人等均造成不利影响,并在资本市场中引发较大波动。其一,连续大额的处罚让凯乐科技自身陷入经营困境;其二,凯乐科技的诸多高管均遭受到个体处罚,个人财富遭损害,未来职业发展亦被影响;其三,中小股东被迫共担处罚结果,遭受经济损失,且相关利空消息也会削弱股东所持股票的价值与流动性;其四,上述不利信息的堆砌损害了债权人信心,引发提前求偿,提升企业面临的债务违约风险;其五,凯乐科技违规事件在资本市场中蔓延,催生出相关方对中国高科技板块乃至整个市场的信任危机。

3 财务违规识别模型的构建

本文按如下思路构建模型,以确保学术性、科学性与准确性:首先,根据三角形理论中机会、借口与压力三个维度来初步选取指标项目;其次,选取中国发生过财务违规的上市公司作为实验组,并匹配未违规企业为对照组来剔除不显著的指标项目,再利用 Boruta 算法约简指标体系;再者,分别使用朴素贝叶斯模型、CART 决策树模型、梯度提升机模型及 XGBoost 模型进行估计,比较结果以挑选出最适方法组合。

3.1 数据来源与处理

3.1.1 样本选取

本文选取 2013—2022 年 A 股上市公司中发生违规的 2387 家公司作为实验组。进一步地,按照 1:1 的比例,遵循以下原则匹配选取 2387 家非违规公司作为对照组:(1) 未被证监会或其他官方机构处罚过;(2) 与违规样本总资产相近(± 0.5 倍);(3) 与实验组时间接近(间隔不超过两年);(4) 非 ST、PT 的上市公司。最终,本文合计选取 4774 家上市公司作为样本。数据主要来源于国泰安(CSMAR)数据库,并使用中国研究数据服务平台(CNRDS)进行交叉验证。

3.1.2 数据处理

本文数据处理中的三大关键点分别为缺失值、重复值与标准化。第一,本文剔除整体数据缺失率大于 60% 的指标,因其缺乏大量有价值的信息;对于整体缺失率小于 60% 的指标,本文则分别使用中位数及众数补充缺失的数量型与类别型数据。第

二,本文选取企业首次违规事件作为样本以保证数据的唯一性。第三,本文将数据去量纲的标准化,以削弱因度量单位与取值范围差异导致的不可比问题。具体方法如式(1)所示:

$$x_{ij} = \frac{a_{ij} - a_{\min}}{a_{\max} - a_{\min}} \quad (1)$$

其中, a_{ij} 表示第 i 个样本的第 j 项指标值, $a_{\max}$ 、 $a_{\min}$ 表示第 j 项指标的最大值和最小值。

3.2 指标体系确定

指标选取是构建识别模型的基础,其种类与数量直接影响到识别模型的有效性。定性选择及定量与定量结合选择,是普遍应用的两种指标选择方式。定性选择指研究人员主观挑选能够反映财务违规的指标,但具有客观性不足的弊端。定性与定量结合的方式则能够缓解此问题,先主观初步选择指标,而后采用算法进行约简。本文采取第二种方法,并在定性选择时以三角形理论为指引,来保证所选指标体系兼具客观性与学理性。

3.2.1 指标初步选择

本文以兼具易理解与易操作特性且应用广泛的三角形理论为初步选择指标的理论指引,见图1。《2023年舞弊风险管理指南(第二版)》(COSO

Fraud Risk Management Guide II,下文简称《舞弊风险管理指南》)将三角形理论中的机会因素界定为:提供给个体某种让其实施违规行为而不易被发现的手段。据此,机会维度应主要包含企业股权与组织结构对财务违规约束不足、隐蔽的供应链关联交易,以及利用管理层语调等难以监管的信息披露来诱导投资者等几个方面。

《舞弊风险管理指南》将借口界定为:使个体在内心为自身实施的违规行为进行辩解的态度或理由。因违规合理化的态度主要与高管特征相关,本文将管理层年龄、性别、教育与性格等个人特征及持股比例作为指标。此外,SAS No. 99将同审计师沟通失效、对审计师加以限制,及可能导致的审计师出具保留意见书等外部审计指标均作为借口维度的实例。因而,本文将外部审计相关指标作为借口维度的度量,此举亦符合现有研究的做法^[33-34]。

《舞弊风险管理指南》将压力界定为:可能驱使个体实施违规行为的激励与压力,包含为实现特定财务绩效与满足外部相关者偏好的压力等。相应地,本文使用企业的主要财务与市场指标来衡量企业的业绩压力,并使用分析师关注与媒体报道来度量企业向外部相关者传递积极信号的压力。




图1 三角形理论构成及内涵

Figure 1 Structure and connotation of fraud triangle theory

三角形理论表达式如式2所示。本文综合考量SAS No. 99、现存相关研究及我国实际情况,挑选出可能识别财务违规的指标项目,表1 Panel A~Panel C分别展示围绕机会、借口与压力三个维度所选取的明细指标及其说明。

$$\text{Misconduct} = f(\text{Opportunity}, \text{Rationalization}, \text{Pressure}) \quad (2)$$

本文在指标体系中的创新,除将三角形理论作为理论指引外,还新颖地引入管理层语调等非结构化数据,以及分析师关注度与媒体监督这两个企业外部环境指标。管理层语调一般基于财务报告中管理层讨论与分析章节进行构建,其作为财务报告中的文本信息,相对财务指标更为主观,难以被标准化监管^[35]。管理层常以此实施掩饰经营业绩、误

导投资者、操纵股价等违规行为^[36]。可见,企业当年的管理层语调较为符合机会因素的界定。现有研究亦大多如此划分,以增加模型识别的准确度^[15,37]。因此,本文参考已有研究^[38],利用式(3)计算企业当年管理层讨论与分析部分的管理层语调。其中,Positive是当年管理层讨论与分析中的正面语调词个数;Negative则是负面语调词个数。TONE为净乐观语调,其值越大,说明管理层用词越积极。

$$\text{TONE} = \frac{\text{Positive} - \text{Negative}}{\text{Positive} + \text{Negative}} \quad (3)$$

分析师及媒体作为重要信息中介,能够引导其他相关者对企业的判断^[39-40]。分析师出于投资收益与自身声誉的考量,仅会跟踪其看好的公司^[39],

表 1 财务违规识别模型的指标体系
Table 1 The index system of financial misconduct identification model

指标名称	序号	指标定义
Panel A 机会维度		
流通股占比	X1	可流通股占总股本的比例
国有股比例	X2	国有股占总股本的比例
法人股比例	X3	法人股占总股本的比例
股东大会出席率	X4	出席股东大会的股东或股东代表所持股份占总股本的比例
内部控制指数	X5	深圳迪博公司发布的内部控制指数
董事会会议次数	X6	所属年度董事会会议次数
董事会规模	X7	所属年度董事会人数
监事会规模	X8	所属年度监事会人数
独立董事比例	X9	年末在职独立董事数量/董事会总人数
两职合一	X10	董事长是否兼任总经理,是则取 1,否则取 0
管理层更迭	X11	若董事长或总经理发生变更,则取 1,否则取 0
股权集中度	X12	公司前 10 位大股东持股比例的平方和
第一大股东控制度	X13	公司第一大股东与第二大股东持股比例的比值
是否设置审计委员会	X14	若设置审计委员会,则取 1,否则取 0
审计委员会规模	X15	所属年度审计委员会人数
关联交易	X16	当年公司全部关联交易额之和与期末资产之比来衡量
管理层语调	X17	式(3) TONE 值
Panel B 借口维度		
审计意见	X18	是否出具标准的无保留意见,是则取 1,否则取 0
事务所更换	X19	是否发生事务所更换,是则取 1,否则取 0
审计师是否来自国际四大	X20	若审计师来自国际四大则取 1,否则取 0
审计师是否来自国内十大	X21	若审计师来自国内十大则取 1,否则取 0
应计水平	X22	$(\text{净利润}-\text{经营活动产生的现金流量净额})/(\text{总资产})$
应计方向	X23	若应计水平为正,则取值为 1,否则取 0
管理层平均年龄	X24	已披露的管理层平均年龄
高管平均教育背景	X25	已披露的管理层平均教育水平
管理者自负	X26	高管中薪酬最高的前三名的薪酬之和/高管薪酬总额
高管人员持股	X27	$(\text{高管人员持股数}+1)$ 的自然对数
高管性别比例	X28	高管女性占比
Panel C 压力维度		
资产负债率	X29	负债合计/资产总计
流动比率	X30	流动资产/流动负债
速动比率	X31	$(\text{流动资产}-\text{存货})/\text{流动负债}$
现金比率	X32	现金及现金等价物期末余额/流动负债
权益乘数	X33	资产总计/所有者权益合计
产权比率	X34	负债合计/所有者权益合计
总资产净利润率	X35	净利润/总资产
营业毛利率	X36	$(\text{营业收入}-\text{营业成本})/\text{营业收入}$
营业净利率	X37	净利润/营业收入
总资产周转率	X38	营业收入/平均资产总额
固定资产周转率	X39	营业收入/固定资产期末净额
应收账款周转率	X40	营业成本/应收账款期末余额
存货周转率	X41	营业成本/存货期末余额
全部现金回收率	X42	经营活动现金净流量/资产总计
总资产增长率	X43	$(\text{年末资产总额}-\text{年初资产总额})/\text{年初资产总额}$
净利润增长率	X44	$(\text{年末净利润额}-\text{年初净利润额})/\text{年初净利润额}$
营业收入增长率	X45	$(\text{年末营业收入}-\text{年初营业收入})/\text{年初营业收入}$
净资产收益率增长率	X46	$(\text{本年净资产收益率}-\text{上年净资产收益率})/\text{上年净资产收益率}$
基本每股收益	X47	净利润/普通股总数
会计信息披露及时性	X48	上一会计年度结束日与年报实际披露日的时间间隔
分析师关注	X49	关注企业的分析师人数加 1 的自然对数
媒体态度	X50	式(4) J-F 系数

投资者等其他相关者也会据此评估企业^[39,41],从而催生出企业为获取分析师关注而美化自身业绩的动机。于是,本文以企业分析师跟踪人数加1的自然对数来衡量其分析师关注。媒体亦具有类似的效应^[42],催生出企业为获取积极报道而美化自身业绩的动机。本文借鉴现有做法^[43],使用式(4)计算出的 *Janis-Fadner* (*J-F*) 系数量化媒体态度。其中, e 与 c 分别为正面及负面媒体报道数量, t 为正面与负面报道数量之和。*J-F*系数的取值范围为 $-1 \sim 1$,*J-F*系数越接近1,代表媒体态度越积极;反之,越消极。

$$J-F \text{ 系数} = \begin{cases} \frac{e^2 - ec}{t^2} & \text{if } e > c \\ \frac{ec - c^2}{t^2} & \text{if } e < c \\ 0 & \text{if } e = c \end{cases} \quad (4)$$

3.2.2 指标显著性检验

本文基于匹配后获得的4774个样本,使用Mann-Whitney检验所选指标的显著性,并剔除无法通过统计检验的指标项目。Mann-Whitney检验是一种非参数检验,不依赖于数据分布的假设。其将两个样本的观测值合并后,通过比较秩次大小来判断中位数是否存在显著差异。当数据不满足正态分布假设或样本容量较小时,其具有更优的统计特性。本文使用KS检验变量的统计分布,发现哑变量外的其余变量亦不满足正态分布(结果留存备索),所以本文使用Mann-Whitney检验更为合适。测试结果显示,共有39个指标通过5%水平下的显著性检验,其中包含机会指标12个、借口指标8个、压力指标19个,见表2。

3.2.3 Boruta 算法约简

本文利用Boruta算法对通过显著性检验的39个指标继续约简,以缓解指标项目过多引致的减慢运行速度、占用过多资源^[44]、潜在过拟合现象,以及损害算法准确率与稳健性等弊端。Boruta算法是一种在机器学习中用于选择重要特征的常见工具,能够缓解特征选择中的随机错误。更重要地,Boruta算法与已有方法在特征选择方面的目标导向具有差异,可以筛选出所有与因变量相关的特征集合^[45]。Boruta算法在初筛的39个指标中进一步选取出表3所列的34个指标项目。

3.3 财务违规识别模型构建

本文构建的财务违规识别模型包含整体与三个子维度两个层次,在分别使用多种机器学习方法进行分析与比较后,借助混淆矩阵展现出分类器的结果。首先,将包含整体财务违规34个项目的

表2 Mann-Whitney 检验结果
Table 2 Result for the Mann-Whitney test

序号	显著性	是否通过检验	序号	显著性	是否通过检验
X1	0.000	是	X26	0.504	否
X2	0.000	是	X27	0.728	否
X3	0.000	是	X28	0.049	是
X4	0.000	是	X29	0.000	是
X5	0.000	是	X30	0.000	是
X6	0.000	是	X31	0.000	是
X7	0.818	否	X32	0.000	是
X8	0.487	否	X33	0.000	是
X9	0.106	否	X34	0.000	是
X10	0.000	是	X35	0.000	是
X11	0.000	是	X36	0.000	是
X12	0.000	是	X37	0.000	是
X13	0.089	否	X38	0.000	是
X14	0.000	是	X39	0.000	是
X15	0.937	否	X40	0.000	是
X16	0.000	是	X41	0.001	是
X17	0.000	是	X42	0.000	是
X18	0.000	是	X43	0.000	是
X19	0.000	是	X44	0.198	否
X20	0.000	是	X45	0.969	否
X21	0.044	是	X46	0.000	是
X22	0.053	否	X47	0.000	是
X23	0.000	是	X48	0.084	否
X24	0.002	是	X49	0.000	是
X25	0.000	是	X50	0.003	是

指标体系记为R-整体。其次,针对企业财务违规所面临的机会、借口与压力程度,设置第二层次,分别记为R-机会、R-借口和R-压力。再者,使用R语言软件,参照文献做法,对全样本数据按7:3的比例划分成训练集和测试集^[46],并分别采用朴素贝叶斯、CART决策树、梯度提升机、XGBoost模型得到估计参数,再利用测试样本进行预测与分析。其中,分别使用交叉验证与网格搜索算法对模型进行调优。最后,使用混淆矩阵这一可视化工具来评估分类器结果。

3.3.1 朴素贝叶斯模型

朴素贝叶斯模型的核心思想为,利用已知训练样本计算条件概率以进行分类^[47]。其应用于财务违规识别中的逻辑为,根据上述选取的指标,计算企业财务违规的条件概率,进而判断企业是否会发生违规。具体地,本文使用expand_grid函数创建包含三个可能取值组合的参数网格bayesGrid;第一步,指定名为fl的参数,其可能的取值为0;第二步,指定名为usekernel的参数,其可能的取值为TRUE;第三步,指定名为adjust的参数,其可能的取值为0.5和1,通过对其训练和评估,发现最优取值为1

表 3 Boruta 算法选取指标的结果
Table 3 Result for the Boruta index selection

指标名称	序号	指标名称	序号
机会指标		压力指标	
流通股占比	X1	资产负债率	X29
国有股比例	X2	流动比率	X30
法人股比例	X3	速动比率	X31
股东大会出席率	X4	现金比率	X32
内部控制指数	X5	权益乘数	X33
董事会会议次数	X6	总资产净利润率	X35
管理层更迭	X11	营业毛利率	X36
股权集中度	X12	营业净利率	X37
是否设置审计委员会	X14	总资产周转率	X38
关联交易	X16	固定资产周转率	X39
管理层语调	X17	应收账款周转率	X40
借口指标		存货周转率	X41
审计意见	X18	全部现金回收率	X42
事务所更换	X19	总资产增长率	X43
审计师是否来自国际四大	X20	净资产收益率增长率	X46
应计方向	X23	基本每股收益	X47
高管平均教育背景	X25	分析师关注度	X49
		媒体监督	X50

的情况。识别结果在混淆矩阵中的展示如表 4 所示。使用朴素贝叶斯模型识别企业违规具有对小规模数据有效、可处理大量特征和高维数据等优点。但其要求满足特征之间相互独立的前提假设,所以可能会牺牲一定的准确率。

表 4 朴素贝叶斯模型识别效果
Table 4 Identification effect of naive Bayes model

风险类别	训练样本			测试样本		
	预测			预测		
R-整体	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1326	380	<i>T</i>	488	193
	<i>F</i>	287	1348	<i>F</i>	151	601
R-机会	预测			预测		
	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1355	351	<i>T</i>	547	134
R-借口	<i>F</i>	368	1267	<i>F</i>	165	587
	预测			预测		
	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
R-压力	<i>T</i>	210	1496	<i>T</i>	79	602
	<i>F</i>	97	1538	<i>F</i>	36	716
	预测			预测		
	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
R-压力	<i>T</i>	1255	451	<i>T</i>	453	228
	<i>F</i>	446	1189	<i>F</i>	215	537

注:*TP*、*FP*、*TN*、*FN* 含义为:*TP* 为正确识别财务违规公司的数量、*FN* 为把财务违规公司错误识别为非违规公司的数量、*FP* 为把非财务违规公司错误识别为违规公司的数量、*TN* 为正确判别非财务违规公司的数量。下文同。

3.3.2 CART 决策树模型

CART 决策树是基于一系列 if-else 规则形成的二叉树模型,其根据特定指标选择最佳的特征进行划分^[46],使得划分后的子集误差更小。使用决策树模型识别企业财务违规的核心思想是通过树状结构进行数据分类和预测。具体地,本文使用 expand.grid 函数创建一个包含各种参数组合的数据框 cartGrid。设定 cp 为剪枝参数,用于控制决策树的复杂度与泛化能力,并指定 0.001、0.01、0.1 及 1 四个候选值。针对每个参数组合进行决策树模型的训练和评估,找到最佳的 cp=1。识别结果如表 5 所示。使用 CART 决策树模型识别企业违规具有直观可见、易于理解与解释的优点。但是,决策树模型在处理复杂数据集时可能出现过拟合问题,本文采用剪枝技术进行应对。

3.3.3 梯度提升机模型

梯度提升机通过迭代训练多个弱预测模型来将它们组合成一个强预测模型^[28]。使用梯度提升机模型识别企业的财务违规能够在决策树模型的基础上进一步降低模型的偏差并提高其泛化能力。具体地,本文使用 R 语言中的 caret 包训练一个基于梯度提升机算法的回归模型,并进行参数调优。梯度提升机模型优化后的参数如表 6 Panel A 所示,识别结果如表 6 Panel B 所示。使用梯度提升机模型识别企业违规,具有预测准确性与灵活性高等优点,但多次迭代过程也会放大其训练时间与内存消耗。

表 5 决策树模型识别效果

Table 5 Identification effect of decision tree model

风险类别	训练样本			测试样本		
	预测			预测		
R-整体	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1551	155	<i>T</i>	566	115
	<i>F</i>	204	1431	<i>F</i>	144	608
R-机会	预测			预测		
	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1571	135	<i>T</i>	619	62
R-借口	<i>F</i>	455	1180	<i>F</i>	191	561
	预测			预测		
	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
R-压力	<i>T</i>	1037	669	<i>T</i>	405	276
	<i>F</i>	519	1116	<i>F</i>	242	510
	预测			预测		
R-压力	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1373	333	<i>T</i>	541	140
	<i>F</i>	456	1179	<i>F</i>	231	521

表 6 梯度提升机模型识别效果

Table 6 Identification effect of gradient elevator model

Panel A 梯度提升机模型算法优化后参数						
模型中参数名称		参数定义			最优参数	
n. trees		基础模型的数量			200	
interaction. depth		树的最大深度参数			5	
shrinkage		学习率			0.1	
n. minobsinnode		每个节点的最小观测数			10	
Panel B 梯度提升机模型识别效果						
风险类别		训练样本			测试样本	
		预测			预测	
R-整体	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1576	130	<i>T</i>	591	90
	<i>F</i>	210	1425	<i>F</i>	132	620
		预测			预测	
R-机会	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1552	154	<i>T</i>	597	84
	<i>F</i>	359	1276	<i>F</i>	152	600
		预测			预测	
R-借口	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1051	655	<i>T</i>	414	267
	<i>F</i>	519	1116	<i>F</i>	245	507
		预测			预测	
R-压力	实际	<i>T</i>	<i>F</i>	实际	<i>T</i>	<i>F</i>
	<i>T</i>	1533	173	<i>T</i>	552	129
	<i>F</i>	275	1360	<i>F</i>	198	554

3.3.4 XGBoost 模型

XGBoost 模型是处理分类问题性能优异的训练模型,是对决策树与梯度提升机模型的再优化。使用 XGBoost 模型识别企业财务违规有助于选择最有利于识别违规行为的特征,并缓解上述提及的过拟

合问题。具体地,本文使用 `expand. grid` 函数创建一个包含各种参数组合的数据框 `xgbGrid`,关于 XGBoost 算法优化后的参数如表 7 Panel A 所示,识别结果如表 7 Panel B 所示。XGBoost 模型具有强大的特征选择能力和正则化手段,在识别企业违规的任务中表现出色,但也存在训练时间长、调优复杂、内存消耗大等不足。

表 7 XGBoost 模型识别效果

Table 7 Identification effect of XGBoost model

Panel A XGBoost 算法优化后参数						
模型中参数名称		参数定义			最优参数	
eta		学习率			0.3	
max_depth		树的最大深度参数			1	
colsample_bytree		每棵树随机选择特征的比例			0.8	
subsample		列抽样比例			1	
nrounds		树的数量			50	
gamma		可继续分裂临界值			0	
min_child_weight		叶子节点的样本权重和			10	
Panel B XGBoost 模型识别效果						
风险类别		训练样本			测试样本	
R-整体		预测			预测	
	实际	T	F	实际	T	F
	T	1590	116	T	571	110
	F	159	1476	F	121	631
		预测			预测	
R-机会	实际	T	F	实际	T	F
	T	1541	165	T	603	78
	F	328	1307	F	146	606
		预测			预测	
	实际	T	F	实际	T	F
R-借口	T	1050	656	T	397	284
	F	492	1143	F	237	515
		预测			预测	
	实际	T	F	实际	T	F
	T	1564	142	T	547	134
R-压力	F	237	1398	F	210	542

3.4 模型比较与算法优选

本节旨在评价各机器学习方法的识别能力,并选出最适组合。本文基于混淆矩阵结果分别使用准确率、精确率、召回率、F 度量、AUC 指标及 ROC 曲线等对预测结果进行评价与比较(各指标含义与计算方式留存备索)。基于整体及三个子维度的各自评价结果如表 8 所示,ROC 曲线结果如图 2 所示。

结果表明:识别企业整体财务违规风险时,梯度提升机模型预测结果的准确率为 84.51%,召回率为 86.78%,F-Score 为 84.19%,AUC 值为 0.905,各指标更优,故记为 R-整体 & 梯度提升机模型;识别机会维度违规风险时,XGBoost 模型的准确率为

表 8 各模型识别效果比较与优选
Table 8 Comparison and optimization of identification effect of each model

风险类别	分类器类型	准确率	精确率	召回率	F-score	AUC	优选排序
R-整体	朴素贝叶斯	75.99%	71.66%	77.73%	73.94%	0.822	4
	决策树	81.93%	79.72%	83.11%	81.38%	0.878	3
	梯度提升机	84.51%	81.74%	86.78%	84.19%	0.905	1
	XGBoost	83.88%	82.51%	83.85%	83.18%	0.901	2
R-机会	朴素贝叶斯	79.20%	76.49%	81.20%	78.77%	0.884	3
	决策树	83.11%	80.19%	85.61%	82.81%	0.854	4
	梯度提升机	83.53%	79.71%	87.67%	83.50%	0.888	2
	XGBoost	83.60%	79.27%	88.69%	83.71%	0.898	1
R-借口	朴素贝叶斯	55.48%	68.70%	11.60%	19.85%	0.678	4
	决策树	63.85%	62.60%	59.47%	60.99%	0.642	3
	梯度提升机	64.27%	62.82%	60.79%	61.79%	0.672	1
	XGBoost	63.64%	62.62%	58.30%	60.38%	0.671	2
R-压力	朴素贝叶斯	69.23%	68.46%	65.35%	66.87%	0.746	4
	决策树	74.11%	70.08%	79.44%	74.47%	0.785	3
	梯度提升机	77.18%	73.60%	81.06%	77.15%	0.851	1
	XGBoost	77.25%	74.02%	80.32%	77.04%	0.833	2




图 2 ROC 曲线结果
Figure 2 Result of ROC curve

83.60%、精确率为 79.27%、召回率为 88.69%、F-score 为 83.71%、AUC 值为 0.898,各指标更优,故记为 R-机会 & XGBoost 模型;识别借口维度违规风险时,各模型的效果近似,但梯度提升机模型表现更为平稳,故记为 R-借口 & 梯度提升机模型。识别压力维度违规时,梯度提升机模型的准确率为 77.18%、精确率为 73.60%、召回率为 81.06%、F-score 为 77.04%、AUC 值为 0.833,均表现更好,

故记为 R-压力 & 梯度提升机模型。

图 2 的 ROC 曲线直观地展现出各方法在识别时的效果。ROC 曲线(receiver operator characteristic curve)是一种评估分类模型性能的重要工具,十分适用于比较不同模型在识别企业财务违规时的效果。ROC 曲线的横坐标为特异度,指将未违规的企业正确分类的比例,纵坐标灵敏度是指将违规企业正确分类的比例^[15]。ROC 曲线覆盖面积越大,说

明模型识别性能越好。本文所构建的识别模型覆盖面积均大于 0.5,说明模型具有一定的识别效果。同时,整体、机会、压力、借口等四个维度的 ROC 曲线的覆盖面积依次递减,说明识别效果由高到低排序依次为:R 整体>R 机会>R 压力>R 借口。这可能是因为借口因素难以度量,缺乏充分的指标来支撑相关分析。此外,就各维度而言,整体中梯度提升机模型代表曲线的覆盖面积最大,机会中 XGBoost 模型的覆盖面积最大,借口中各模型接近,梯度提升机模型稍有突出,压力中梯度提升机模型的覆盖面积最大。所以,本文选取的各情况下识别模型均为各自最优策略,共同构成一个整体有效的财务违规识别模型。

4 案例应用与讨论分析

为了更直观地展现出所构建财务违规识别模型的应用过程,本文将其实用于符合理论抽样的凯乐科技案例。具体步骤为:(1)将凯乐科技的实际

值代入上述模型计算出违规预测值;(2)本文使用 0.5 作为识别企业是否违规的判断阈值。根据贝叶斯决策理论,在不存在特别偏好的情况下,使用 0.5 作为判断阈值能够最大化分类准确率;(3)将预测值(P)与阈值比较,当 P 大于 0.5 时,则预期存在财务违规行为;反之,不存在;(4)根据模型识别结果划分违规与非违规组。

4.1 整体财务违规应用结果

本文所构建的 R-整体 & 梯度提升机模型测算出的凯乐科技 2014—2021 年整体违规概率均大于 0.5。说明基于识别结果,凯乐科技在 2014—2021 年均有一定的可能出现财务违规行为,见表 9。实际上,除 2015 年以外,凯乐科技确实均发生了财务违规事件。此外,本文构建的模型虽然识别出凯乐科技将会在 2015 年发生财务违规,但计算出的数值却是 2014—2021 年中最低的。以上结果表明,本文所构建的财务违规识别模型兼具信度与效度,基本实现了模型设计的初衷。

表 9 R-整体 & 梯度提升机模型凯乐科技财务违规识别结果

Table 9 R-integral & gradient elevator model financial irregularities identification results of Kailo Technology

指标	内容							
年度	2014	2015	2016	2017	2018	2019	2020	2021
P	0.91	0.82	0.97	0.94	0.90	0.96	0.99	0.96
模型判断是否发生违规	是	是	是	是	是	是	是	是
实际是否发生违规	是	否	是	是	是	是	是	是

4.2 财务违规中机会维度应用结果

本文所构建的 R-机会 & XGBoost 模型围绕凯乐科技 2014—2021 年机会维度的 12 个相关指标进行测算,结果如表 10 Panel A 所示。凯乐科技财务违规机会的识别结果均大于 0.5,表明其在 2014—2021 年间一直存在着较高的违规机会概率。进一步地,使用识别模型计算每个明细项目的违规概率,结果如表 10 Panel B 所示,发现 X1、X3、X6、X11、X12、X14 等治理结构方面、X5 代表的内部控制方面及 X16 与 X17 等信息监管方面均存在较高的财务违规风险。

4.2.1 公司治理不完善

凯乐科技治理结构中存在所有权与控制权重合的漏洞,阻碍了内部的制约与监督。积极履责的董事会、监事会与高管团队有助于防范财务违规事件的发生。但凯乐科技董事长与总经理为父子关系,造成了公司的所有权与控制权高度重合,妨碍了治理层的相互制约与监督。此外,审计委员会等外部独董也难以在此种失衡结构下发挥应有的监督功效,为实施不端行为提供了可乘之机。

4.2.2 内部控制流于形式

凯乐科技的内部控制流于形式,未能发挥防范

违规问题的功效。凯乐科技虽每年进行内部控制自我评价与审计鉴证,但其相关工作并未发挥实际功效。其伪造合同、虚构业务等违规手段基本涵盖从采购至入库的全流程。内部控制本应在这些流程中确保程序合规,但却未能识别违规风险并抑制违规行为的发生。

4.2.3 信息监管困难

凯乐科技利用专网通信业务涉密、文本信息缺乏规范标准的特点规避外部监管,为实施财务违规行为提供可乘之机。专网通信业务相较公网通信业务具有更高保密要求,可以不公开招标与对外披露,为通过供应链的关联交易实施违规行为提供了机会。同时,管理层语调这种文本信息没有规范的披露标准,凯乐科技亦抓住此特点,有方向地引导投资者等相关方的判断。

4.3 财务违规中借口维度应用结果

本文利用所构建的 R-借口 & 梯度提升机模型,计算凯乐科技 2014—2021 年的 5 个借口相关指标。表 11 Panel A 显示,除 2020 年外,凯乐科技在 2014—2021 年间借口维度的违规概率多在阈值 0.5 以上,但未超出太多,说明其存在一定程度的违规

表 10 R-机会 & XGBoost 模型识别结果与排序
Table 10 R-chance & XGBoost model identification results and ranking

Panel A R-机会 & XGBoost 模型识别结果											
年度	2014	2015	2016	2017	2018	2019	2020	2021			
P	0.86	0.8	0.79	0.82	0.84	0.92	0.91	0.91			
Panel B 凯乐科技“机会”维度分指标违规概率											
年度	X1	X2	X3	X4	X5	X6	X11	X12	X14	X16	X17
2013	0.66	0.47	0.84	0.49	0.57	0.61	0.74	0.66	0.52	0.67	0.59
2014	0.66	0.47	0.84	0.49	0.57	0.61	0.74	0.66	0.52	0.73	0.54
2015	0.64	0.47	0.4	0.49	0.57	0.61	0.74	0.65	0.52	0.71	0.43
2016	0.64	0.47	0.4	0.49	0.57	0.61	0.74	0.65	0.52	0.61	0.51
2017	0.54	0.47	0.4	0.49	0.57	0.61	0.74	0.56	0.52	0.67	0.54
2018	0.61	0.47	0.4	0.49	0.57	0.61	0.74	0.56	0.52	0.73	0.59
2019	0.61	0.47	0.43	0.49	0.57	0.66	0.74	0.74	0.52	0.61	0.64
2020	0.61	0.47	0.48	0.49	0.57	0.66	0.3	0.73	0.52	0.68	0.69
2021	0.66	0.47	0.84	0.49	0.57	0.64	0.74	0.69	0.52	0.84	0.76

借口。进一步地,使用所构建模型计算每个明细项目的违规概率。表 11 Panel B 显示,X18、X19、X20 所代表的外部审计,及 X25 所代表的高管学历背景

均大于等于 0.5。所以,理应从外部审计以及管理层教育两个维度具体分析凯乐科技财务违规的借口。

表 11 R-借口 & 梯度提升机模型识别结果与排序
Table 11 R-excuse & gradient elevator model identification results and ranking

Panel A R-借口 & 梯度提升机模型识别结果										
年度	2013	2014	2015	2016	2017	2018	2019	2020	2021	
P	0.54	0.6	0.57	0.59	0.59	0.57	0.57	0.46	0.61	
Panel B 凯乐科技“借口”维度分指标违规概率										
年度	X18		X19		X20		X23		X25	
2013	0.5		0.5		0.52		0.45		0.6	
2014	0.5		0.5		0.52		0.62		0.61	
2015	0.5		0.5		0.52		0.45		0.6	
2016	0.5		0.58		0.52		0.62		0.6	
2017	0.5		0.5		0.52		0.62		0.6	
2018	0.5		0.5		0.52		0.45		0.6	
2019	0.5		0.5		0.52		0.45		0.6	
2020	0.5		0.5		0.52		0.45		0.53	
2021	0.9		0.5		0.52		0.45		0.5	

4.3.1 外部审计缺位

外部审查机构未发现不当之处,为凯乐科技合理化自身的财务违规提供了理由。外部审计在鉴证财务信息时有义务识别企业的违规行为。中天运会计师事务所连续 6 年为凯乐科技提供内控与财报审计服务,但始终未能识别其连续 5 年的利润造假,这一事实揭示出审计质量的缺陷。

4.3.2 高管教育不足

凯乐科技的违规很大程度上源于高管未能起到内部“吹哨人”的作用。为达成抬高股价以牟取个人收益的目的,董事长等人自 2016 年开始实施了长达 5 年的财务违规行为,且整个集团的大部分高管均参与其中。而且,整个专网通信业务的审批流

程在各环节均有专门负责的高管,却未有一人对外披露,为违规实施主体合理化自身行为提供了理由。

4.4 财务违规中压力维度应用结果

本文利用构建的 R-压力 & 梯度提升机模型,计算凯乐科技 2014—2021 年的 17 个压力相关指标。表 12 Panel A 显示,凯乐科技 2014—2021 年间压力维度的识别结果均远大于 0.5,表明其一直具有较高的违规压力。进一步地,利用所构建模型测算各明细项目的违规概率。表 12 Panel B 显示,X29~X33、X36、X37、X41 所对应的财务指标的识别概率均大于等于 0.5,说明财务业绩压力及其对上市地位的潜在威胁是凯乐科技违规的主要压力来源。

表 12 R-压力 & 梯度提升机模型识别结果与排序
Table 12 R-motivation & gradient elevator model identification results and ranking

Panel A R-压力 & 梯度提升机模型识别结果																		
年度	2014		2015		2016		2017		2018		2019		2020		2021			
P	0.75		0.7		0.94		0.92		0.91		0.73		0.89		0.55			
Panel B 凯乐科技“压力”维度分指标违规概率																		
年度	X29	X30	X31	X32	X33	X35	X36	X37	X38	X39	X40	X41	X42	X43	X46	X47	X49	X50
2013	0.67	0.68	0.68	0.69	0.61	0.72	0.50	0.62	0.54	0.54	0.49	0.56	0.45	0.68	0.34	0.64	0.49	0.62
2014	0.67	0.67	0.68	0.68	0.62	0.76	0.52	0.66	0.60	0.56	0.49	0.55	0.59	0.70	0.39	0.68	0.54	0.41
2015	0.66	0.67	0.66	0.66	0.61	0.73	0.54	0.61	0.55	0.49	0.48	0.54	0.50	0.43	0.63	0.61	0.54	0.41
2016	0.68	0.66	0.66	0.75	0.62	0.52	0.60	0.66	0.43	0.47	0.50	0.50	0.70	0.22	0.64	0.53	0.48	0.47
2017	0.66	0.67	0.66	0.74	0.61	0.44	0.59	0.61	0.46	0.46	0.49	0.50	0.70	0.55	0.68	0.38	0.58	0.60
2018	0.66	0.65	0.66	0.74	0.61	0.51	0.58	0.61	0.44	0.46	0.46	0.50	0.48	0.61	0.55	0.37	0.58	0.47
2019	0.64	0.67	0.66	0.74	0.59	0.36	0.60	0.61	0.44	0.46	0.48	0.50	0.40	0.85	0.53	0.38	0.55	0.50
2020	0.62	0.63	0.58	0.63	0.58	0.50	0.56	0.62	0.53	0.47	0.48	0.50	0.34	0.79	0.35	0.54	0.48	0.64
2021	0.59	0.67	0.60	0.76	0.37	0.88	0.60	0.62	0.58	0.55	0.48	0.53	0.68	0.85	0.73	0.69	0.46	0.47

4.4.1 财务业绩指标

凯乐科技实施财务违规行为的重要驱动力量为美化财务业绩,以提升股价与市场影响力。凯乐科技2016年少量专网通信业务的合作开展使其各类业绩指标快速提升,公司由此发现,依靠美化自身的业绩指标就可以在资本市场上获得投资者青睐,并大幅提升股价。此种利益诱惑下,凯乐科技选择使用策略性手段铤而走险,营造业绩良好的表象。

4.4.2 稳定上市地位

稳住上市地位是凯乐科技实施财务违规行为的另一重要压力。业绩指标下滑可能威胁上市地位。上市在我国仍是较为稀缺的资源,且证监会对上市公司的业绩指标存在诸多考核要求。凯乐科技在2016—2020年净利润始终为负,各类业绩指标表现较差,放大了其面临的退市风险。此时,财务违规便是一种可以快速实现目标的投机手段。因而,退市压力也催生了凯乐科技的财务违规行为。

4.5 模型有效性的进一步检验

本文首先使用 random 函数随机选择 20 家 2022 年上市公司作为研究对象,其中实际发生与未发生财务违规的公司各 10 家。抽取的样本覆盖制造业、医疗行业、餐饮业等,确保其具有更广泛的代表性。其次,使用所构建的财务违规识别模型计算各企业的违规概率 P 值。再者,将计算出的 P 值与阈值 0.5 进行比较,并得出预测结论。最后,比较预测结论与实际情况以判断模型的有效性。表 13 显示,此 20 家公司中,有 18 家的识别结果是正确的,正确率达到 90%,证明所构建的模型能够有效地识别企业的财务违规行为,并具有较高的普适性。

表 13 20 家随机抽取公司的识别结果
Table 13 Identification results of 20 randomly selected enterprises

股票代码	公司名称	P	是否发生违规	识别结果
000063	中兴通讯	0.96	是	正确
003000	劲仔食品	0.75	是	正确
300791	仙乐健康	0.85	是	正确
600153	建发股份	0.97	是	正确
603127	昭衍新药	0.68	是	正确
603927	中科软	0.80	是	正确
605166	聚合顺	0.84	是	正确
688063	派能科技	0.95	是	正确
688385	复旦微电	0.64	是	正确
871553	凯腾精工	0.40	是	错误
001223	欧克科技	0.05	否	正确
001268	联合精密	0.24	否	正确
001322	箭牌家居	0.10	否	正确
301238	瑞泰新材	0.05	否	正确
301349	信德新材	0.10	否	正确
430476	海能技术	0.63	否	错误
688062	迈威生物	0.0606	否	正确
833429	康比特	0.3307	否	正确
838810	春光药装	0.2267	否	正确
870866	绿亨科技	0.2261	否	正确

5 结论与启示

本文创新性地融合使用大样本与案例研究方法,在三角形理论的指导下,使用多种机器学习方法来构建企业财务违规的识别模型,以响应《舞弊风险管理

指南》对使用新兴技术方法识别企业违规行为的呼吁。本文首先对凯乐科技的案例进行简要回顾;其次,根据三角形理论初步选择指标项目,利用上市公司样本来剔除不显著的指标,并使用算法进行约简,确定指标体系;再者,依托朴素贝叶斯、CART 决策树、梯度提升机、XGBoost 模型等新兴机器学习方法进行参数确定与模型优化,并在比较后挑选出最适组合;此外,将所构建模型应用于凯乐科技实例,发现本文所构建的识别模型能够精准地预测出凯乐科技的潜在违规风险,并直观地展现模型的应用过程;最后,将所构建模型应用于随机抽取的上市公司样本来证实识别模型的普适性。

本文研究结论的启示如下:第一,监管机构要加强对财务违规行为的处罚力度,利用处罚成本来威慑潜在违规主体;第二,上市公司要树立可持续发展理念,避免因财务违规等短视投机行为而自食恶果;第三,要充分发挥会计事务所等中介机构资本市场“看门人”的作用,不断提升其工作能力与独立性。

参 考 文 献

- [1] BEAVER W H. Financial ratios as predictors of failure [J]. *Journal of Accounting Research*, 1966, 4: 71-111.
- [2] BENERSH M D. Detecting GAAP violation: Implications for assessing earnings management among firms with extreme financial performance [J]. *Journal of Accounting and Public Policy*, 1997, 16(3): 271-309.
- [3] LEE T A, INGRAM R W, HOWARD T P. The difference between earnings and operating cash flow as an indicator of financial reporting fraud [J]. *Contemporary Accounting Research*, 1999, 16(4): 749-786.
- [4] 方军雄, 洪剑峭, 李若山. 我国上市公司审计质量影响因素研究: 发现和启示 [J]. *审计研究*, 2004, (6): 35-43.
FANG J X, HONG J Q, LI R S. Research on the influencing factors of audit quality of Chinese listed companies: Findings and enlightenments [J]. *Auditing Research*, 2004, (6): 35-43.
- [5] BEASLEY M S. An empirical analysis of the relation between the board of director composition and financial statement fraud [J]. *Accounting Review*, 1996, 71(4): 443-465.
- [6] BELL T B, CARCELLO J V. A decision aid for assessing the likelihood of fraudulent financial reporting [J]. *Auditing: A Journal of Practice & Theory*, 2000, 19(1): 169-184.
- [7] SOLTES E. Private interaction between firm management and sell-side analysts [J]. *Journal of Accounting Research*, 2014, 52(1): 245-272.
- [8] 刘立国, 杜莹. 公司治理与会计信息质量关系的实证研究 [J]. *会计研究*, 2003, (2): 28-36, 65.
- LIU L G, DU Y. An empirical study on the relationship between corporate governance and the quality of accounting information [J]. *Accounting Research*, 2003, (2): 28-36, 65.
- [9] 周继军, 张旺峰. 内部控制、公司治理与管理者舞弊研究——来自中国上市公司的经验证据 [J]. *中国软科学*, 2011, (8): 141-154.
ZHOU J J, ZHANG W F. The study on internal control, corporate governance and manager fraud: Empirical evidence from Chinese listed companies [J]. *China Soft Science*, 2011, (8): 141-154.
- [10] DECHOW P M, SLOAN R G, SWEENEY A P. Causes and consequences of earnings manipulation: An analysis of firms subject to enforcement actions by the SEC [J]. *Contemporary Accounting Research*, 1996, 13(1): 1-36.
- [11] 于忠泊, 田高良, 齐保奎, 等. 媒体关注的公司治理机制——基于盈余管理视角的考察 [J]. *管理世界*, 2011, (9): 127-140.
YU Z B, TIAN G L, QI B L, et al. Corporate governance mechanism concerned by media: Investigation based on the perspective of earnings management [J]. *Journal of Management World*, 2011, (9): 127-140.
- [12] LOUGHRAN T, MCDONALD B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks [J]. *The Journal of Finance*, 2011, 66(1): 35-65.
- [13] BROWN N C, CROWLEY R M, ELLIOTT W B. What are you saying? Using topic to detect financial misreporting [J]. *Journal of Accounting Research*, 2020, 58(1): 237-291.
- [14] LARCKER D F, ZAKOLYUKINA A A. Detecting deceptive discussions in conference calls [J]. *Journal of Accounting Research*, 2012, 50(2): 495-540.
- [15] 张庆龙, 邢春玉, 张延彪, 等. 上市公司财务违规特征分析及预测研究——基于企业画像和机器学习的经验证据 [J]. *审计研究*, 2023, (2): 73-87.
ZHANG Q L, XING C Y, ZHANG Y B, et al. Research on the analysis and prediction of financial irregularities of listed companies - Empirical evidence based on methods of enterprise portrait and machine learning [J]. *Auditing Research*, 2023, (2): 73-87.
- [16] BAO Y, DATTA A. Simultaneously discovering and quantifying risk types from textual risk disclosures [J]. *Management Science*, 2014, 60(6): 1371-1391.
- [17] PEROLS J. Financial statement fraud detection: An analysis of statistical and machine learning algorithms [J]. *Auditing: A Journal of Practice & Theory*, 2011, 30(2): 19-50.
- [18] 蔡志岳, 吴世农. 我国上市公司信息披露违规的预警研究——基于财务、市场和治理视角 [J]. *管理评论*, 2007, (1): 25-33, 40, 64.
CAI Z Y, WU S N. An empirical study on predicting illegal disclosure of listed companies in China: From the

- perspectives of finance, market and governance [J]. Management Review, 2007, (1): 25-33, 40, 64.
- [19] 酃金梁, 吴谣, 雷曜, 等. 有效预警上市公司违规的递延所得税异动指标和人工智能模型[J]. 金融研究, 2020, (8): 149-168.
- LI J L, WU Y, LEI Y, et al. Fraud detection using deferred income tax: A machine learning perspective[J]. Journal of Financial Research, 2020, (8): 149-168.
- [20] 黄世忠, 叶丰滢. 美国南方保健公司财务舞弊案例剖析——萨班斯—奥克斯利法案颁布后美国司法部督办的第一要案[J]. 会计研究, 2003, (6): 59-63.
- HUANG S Z, YE F Y. Analysis on the case of the US HealthSouth corporation financial fraud [J]. Accounting Research, 2003, (6): 59-63.
- [21] CALDERON T G, GREEN B P. Signaling fraud by using analytical procedures [J]. Ohio CPA Journal, 1994, 53: 27.
- [22] 张健, 刘斌, 吴先聪. 财务舞弊、家族控制与上市公司高管更替[J]. 管理工程学报, 2015, 29(2): 1-9.
- ZHANG J, LIU B, WU X C. Financial fraud, family control and executives' turnover in listed company [J]. Journal of Industrial Engineering and Engineering Management, 2015, 29(2): 1-9.
- [23] BOLOGNA G J, LINDQUIST R J. Fraud auditing and forensic accounting: New tools and techniques[M]. New York: John Wiley & Sons Inc., 1995.
- [24] ALBRECHT W S, WERBZ G W, WILLIAMS T L. Fraud: Bringing light to the dark side of business[M]. Illinois: Irwin Professional Pub., 1995.
- [25] BOLOGNA G J, LINDQUIST R J, WELLS J T. Accountant's handbook of fraud and commercial crime[M]. New York: John Wiley & Sons Inc., 1993.
- [26] 何轩, 朱丽娜, 马骏. 中国上市公司违规行为: 一项以制度环境为视角的经验性研究[J]. 管理工程学报, 2019, 33(4): 61-73.
- HE X, ZHU L N, MA J. Frauds of listed companies in China: An empirical study from the perspective of institutional environment [J]. Journal of Industrial Engineering and Engineering Management, 2019, 33(4): 61-73.
- [27] 柏凤山, 迟国泰, 温武军. 基于 LSTM 和多头注意力机制的企业违约预测模型[J]. 管理工程学报, 2024, 38(3): 213-226.
- BAI F S, CHI G T, WEN W J. Enterprise default prediction model based on LSTM and multi-head attention[J]. Journal of Industrial Engineering and Engineering Management, 2024, 38(3): 213-226.
- [28] FRIEDMAN J H. Greedy function approximation: A gradient boosting machine [J]. Annals of statistics, 2001, 29(5): 1189-1232.
- [29] SAHIN Y, BULKAN S, DUMAN E. A cost-sensitive decision tree approach for fraud detection [J]. Expert Systems with Applications, 2013, 40(15): 5916-5923.
- [30] 吴菲, 唐良红, 冯玉强, 等. 基于预测模型决策树的时间序列模型选择方法研究[J]. 管理工程学报, 2001, (1): 32-35, 2.
- WU F, TANG L H, FENG Y Q, et al. A model selection approach to time series identification by forecasting model decision tree [J]. Journal of Industrial Engineering and Engineering Management, 2001, (1): 32-35, 2.
- [31] JAN C-L. An effective financial statements fraud detection model for the sustainable development of financial markets: Evidence from Taiwan [J]. Sustainability, 2018, 10(2): 513.
- [32] EISENHARDT K M, GRAEBNER M E. Theory building from cases: Opportunities and challenges [J]. Academy of Management Journal, 2007, 50(1): 25-32.
- [33] 伍中信, 陈玲琳. 基于舞弊三角理论对农业上市公司财务报告舞弊的识别研究[J]. 财会月刊, 2015, (15): 3-7.
- WU Z X, CHEN L L. Research on identification of financial reporting fraud of agricultural listed companies based on fraud triangle theory [J]. Finance and Accounting Monthly, 2015, (15): 3-7.
- [34] LOU Y I, WANG M L. Fraud risk factor of the fraud triangle assessing the likelihood of fraudulent financial reporting [J]. Journal of Business & Economics Research, 2009, 7(2): 61-78.
- [35] LI F. The information content of forward-looking statements in corporate filings—A naïve Bayesian machine learning approach [J]. Journal of Accounting Research, 2010, 48(5): 1049-1102.
- [36] HUANG A H, ZANG A Y, ZHENG R. Evidence on the information content of text in analyst reports [J]. Accounting Review, 2014, 89(6): 2151-2180.
- [37] 刘云菁, 伍彬, 张敏. 上市公司财务舞弊识别模型设计及其应用研究——基于新兴机器学习算法[J]. 数量经济技术经济研究, 2022, 39(7): 152-175.
- LIU Y J, WU B, ZHANG M. Financial fraud recognition model and application: Based on emerging machine learning algorithms [J]. The Journal of Quantitative & Technical Economics, 2022, 39(7): 152-175.
- [38] 谢德仁, 林乐. 管理层语调能预示公司未来业绩吗? ——基于我国上市公司年度业绩说明会的文本分析[J]. 会计研究, 2015(2): 20-27, 93.
- XIE D R, LIN L. Do management tones help to forecast firms' future performance: A textual analysis based on annual earnings communication conferences of listed companies in China [J]. Accounting Research, 2015(2): 20-27, 93.
- [39] 危雁麟, 张俊瑞, 汪方军, 等. 数据资产信息披露与分析师盈余预测关系研究——基于文本分析的经验证据[J]. 管理工程学报, 2022, 36(5): 130-141.
- WEI Y L, ZHANG J R, WANG F J, et al. Research of

- data assets disclosure and analyst forecasts: Evidence from text analysis[J]. *Journal of Industrial Engineering and Engineering Management*, 2022, 36(5): 130-141.
- [40] 周开国, 应千伟, 钟畅. 媒体监督能够起到外部治理的作用吗? ——来自中国上市公司违规的证据[J]. *金融研究*, 2016, (6): 193-206.
- ZHOU K G, YING Q W, ZHONG C. Can media coverage improve corporate governance? Evidence from fraud by listed firms in China[J]. *Journal of Financial Research*, 2016, (6): 193-206.
- [41] CHEN T, MARTIN X M. Do bank-affiliated analysts benefit from lending relationships? [J]. *Journal of Accounting Research*, 2011, 49(3): 633-675.
- [42] DYCK A, VOLCHKOVA N, ZINGALES L. The corporate governance role of the media: Evidence from Russia[J]. *The Journal of Finance*, 2008, 63(3): 1093-1135.
- [43] 杨国超, 张李娜. 产业政策何以更有效? ——基于海量媒体报道数据与研发操纵现象的证据[J]. *经济学(季刊)*, 2021, 21(6): 2173-2194.
- YANG G C, ZHANG L N. How to make industrial policy more effective? ——Evidence based on massive media data and R&D manipulation [J]. *China Economic Quarterly*, 2021, 21(6): 2173-2194.
- [44] KUFLIK T, BOGER Z, SHOVAL P. Filtering search results using an optimal set of terms identified by an artificial neural network [J]. *Information Processing & Management*, 2006, 42(2): 469-483.
- [45] KURSA M B, RUDNICKI W R. Feature selection with the Boruta package [J]. *Journal of Statistical Software*, 2010, 36(11): 1-13.
- [46] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016.
- ZHOU Z H. *Machine Learning* [M]. Beijing: Tsinghua University Press, 2016.
- [47] 王双成, 裴瑛, 毕玉江. 经济周期转折点预测的动态贝叶斯网络分类器模型[J]. *管理工程学报*, 2011, 25 (2): 173-177.
- WANG S C, PEI Z, BI Y J. Dynamic Bayesian network classifier model for predicting the cyclical turning points of economic fluctuation [J]. *Journal of Industrial Engineering and Engineering Management*, 2011, 25 (2): 173-177.

A machine learning identification model for corporate financial misconduct —— Based on the case study of Kaile Technology

HUANG Ying¹, KANG Xiaojia¹, TANG Kai^{2*}

(1. School of Management, Zhejiang University, Hangzhou 310058, China;

2. School of Management, Sun Yat-sen University, Guangzhou 510006, China)

Abstract: The presence of corporate financial misconduct can greatly disrupt the smooth functioning and fairness of the capital market, in turn affecting the stability of the broader economy. Due to the growing stealthiness of such malpractice, its occurrence has been on the rise. In the past, researchers have relied on empirical analysis, univariate tests, and regression analysis to uncover the factors driving corporate financial wrongdoing. However, with technological progress, the use of innovative techniques like machine learning to detect financial misconduct has become a recent trend. Though existing studies mainly center on financial fraud and tend to rely on a single methodology to scrutinize a particular aspect, such an approach is insufficient to accurately identify risks of financial misconduct. Consequently, it fails to prevent the potential negative consequences of these occurrences right from the start. Hence, it is imperative to develop a framework that can effectively identify a wider array of corporate financial misconduct using publicly accessible data. This is essential for protecting the interests of various stakeholders, including regulators, investors, creditors, and upstream and downstream supply chain companies.

This paper attempts to construct a model to accurately identify corporate financial misconduct risks by applying it to a typical case to demonstrate its application process clearly and intuitively, so as to provide an effective analytical tool for building a fair and efficient capital market. Specifically, this paper first briefly reviews the financial misconduct case of Kaile Technology. Under the guidance of the fraud triangle theory, a preliminary selection of indicator items is made from the three dimensions of opportunity, excuse, and pressure. After using the non-compliant listed companies and their matched samples to eliminate insignificant items, a refined index system is developed using algorithmic processes, ensuring its theoretical robustness, scientific integrity, reliability, and practicality. Subsequently, machine learning methods such as the Naive Bayes model, CART decision tree model, gradient boosting machine model, and XGBoost model are used to estimate parameters separately, and the most suitable combination for each scenario is selected after comparing various estimation results. Additionally, the constructed financial misconduct identification model is applied to the case of Kaile Technology to demonstrate the working process of the model. Finally, the model is used to estimate a randomly selected sample of listed companies to verify its universal applicability. The research findings indicate that the identification model constructed in this

paper possesses a high level of credibility and validity and is capable of accurately identifying the financial misconduct risks of companies like Kaile Technology, and of elucidating the underlying causes of such incidents from the three dimensions of opportunity, excuse, and pressure.

This paper makes incremental contributions to the existing research in terms of research paradigms, the constructed financial misconduct identification model, and the perspectives adopted. First, it adopts a research paradigm that combines large-sample archival data with typical case studies, innovatively applying a large-sample empirical method to construct a financial misconduct identification model and then applying the model to the typical case of Kaile Technology. This approach intuitively demonstrates the working process of the constructed model, meeting the needs of various stakeholders to understand the application of emerging methods such as machine learning. Second, it uses the well-established fraud triangle theory as the preliminary selection standard for indicator items, ensuring high theoretical relevance while significantly reducing any subjective biases. Moreover, it innovatively introduces unstructured data and external environmental factors into the indicator system, broadening the sources of indicator items for financial misconduct identification. At the same time, after comparing various machine learning identification methods, it selects the most suitable estimation method for each scenario and forms a combination of estimation methods, ensuring that the constructed model is both scientifically sound and feasible. Third, the paper constructs an identification model from a broader perspective, focusing on the increasingly frequent and harmful corporate financial misconduct in the capital market, thereby expanding the model's application scope.

Overall, against the backdrop of the severe and frequent occurrence of corporate financial misconduct in China's capital market, this paper constructs a robust model that is not only academically rigorous and scientifically reliable, but also practical for real-world applications for identifying financial misconduct risks. The model is applied in a typical case study to open up the "black box" of its workings, providing analytical tools and insights to foster the stable and efficient growth of the capital market.

Key words: Financial misconduct; Machine learning; Identification model; Fraud triangle theory

Received Date: 2023-12-01

Funded Project: USyd-ZJU Partnership Collaboration Awards (188170 * 194252404/002); The Zhejiang Research Base of China United Front Theory Research Association

* Corresponding author